

Zhuowei Han

Pfaffenwaldring 44D•70569 Stuttgart• Tel.: 0176/61891464

Tätigkeitsbeschreibung I

09/2013 – 03/2014 Forschungsarbeit, Robert Bosch GmbH, Leonberg

■ Thema

Optimierung und Validierung der Parameter der adaptiven Schwelle im ultraschallbasierten Detektionssystem

■ Aufgabe

1. Auswerte-Algorithmus in Matlab weiterentwickeln mit dem Ziel einer weitgehenden Automatisierung der Tests
2. Ermittlung fehlender Daten/Szenen
3. Entwicklung von Ansätzen zur Verbesserung des Algorithmus

■ Meine Tätigkeiten

Der Cell Averaging Constant False Alarm Rate (CA-CFAR) Algorithmus wird für die Messung der Entfernung zum Objekt im zukünftigen Fahrerassistenzsystem verwendet, welches eine adaptive Schwelle für die Detektion der Amplitudenspitze im zeitlichen Autokorrelationssignal bestimmt. Durch diese Forschungsarbeit soll ein Multiplikatorparameter für diesen Algorithmus optimiert und validiert werden.

1. Durchführung von „Untergrund-Messungen“ ohne Objekt mit verschiedenen Oberflächen
 - a) Aufbau des Messsystems.
 - b) Durchführung der Messung auf dem glatten Boden in der Einbauhalle.

Die Messdaten von dieser Messung werden als Referenz für alle anderen Böden betrachtet, da es im Prinzip kein Bodenecho gibt.
 - c) Durchführung der Messung im Fahrzeug auf Asphalt, Schotter, Pflaster und Gras.
 - d) Troubleshooting der Motorstörung während der Messung im Fahrzeug.

Da die Auswertung der Messdaten aus meinen Messungen mit dem Fahrzeug einen ungewöhnlichen Wert des Parameters ergab, wurde zunächst ein Rauschsignal durch Monitoring während der Messung festgelegt. Anschließend wurde ein Test im Fahrzeug durchgeführt, bei dem der Sensor nur im Empfangsbetrieb arbeitete und nur ein konstantes Rauschsignal erhielt, wenn der Motor im Fahrzeug eingeschaltet wurde. Der Bericht über das Problem wurde in der

Gruppensitzung vorgestellt und diskutiert sowie das Problem anschließend durch Hardware-Ingenieur gelöst.

2. Untersuchung der Parameterabhängigkeit vom Sendemuster

Der Ultraschallsensor wird im Frequenzband von 40 kHz bis 60 kHz mit der Signalbandbreite von 1 kHz bis 9 kHz in einer steigenden oder fallenden Rampe betrieben. Daher beeinflussen die Einflussgrößen des Signals den Parameter:

- a) Mittelfrequenz
- b) Bandbreite
- c) Dauer

3. Untersuchung der Parameterabhängigkeit von der Filterlänge

Die Filterstrecke in der Signalverarbeitungsstufe liefert das Autokorrelationssignal für die Objektdetektion. Wegen den mechanischen Eigenschaften des Ultraschallumwandlers ist der Sensor nicht in der Lage, das akustische Signal gleichzeitig zu senden und zu empfangen. Daher ist das langandauernde Sendemuster im Prinzip nicht für kleine Entfernungen geeignet. Das Filter mit kürzerer Filterlänge als der Sendeimpuls dient dazu, nur den letzten Teil des Empfangssignals für die Berechnung des Autokorrelationssignals zu benutzen. Die Länge des Filters wird durch Messungen untersucht und deren mögliche Einflüsse anhand der Daten erläutert.

4. Optimierung des Parameters unter der Randbedingung einer vorgegebenen Falschalarmrate in verschiedenen Entfernungsbereichen, Nah- und Fernbereich

Im Nahbereich von 0,5 m bis 3,5 m ist die Amplitude des Bodenechos in der Regel deutlich größer als im Fernbereich von 3,5 m bis 6 m. Daher werden alle Daten aus obengenannten Messungen und Untersuchungen in unterschiedlichen Bereichen ausgewertet und die Parameter jeweils für Nah- und Fernbereich optimiert und validiert.

5. Weiterentwicklung des Auswertungstools in Matlab und Entwicklung des Automatisierungstools in Excel VBA

a) Matlab

Die Auswertung soll möglichst automatisiert gestaltet werden, weshalb die Funktionen in den gesamten Code-Rahmen bzw. in die GUI-Oberfläche hinzugefügt werden mussten.

b) Excel VBA

Eine Excel Datei wird als Datenbank für die Ergebnisse der Matlab Auswertung verwendet. Das Auslesen und die grafische Darstellung der Ergebnisse wurde durch ein eigenständig entwickeltes VBA-Tool automatisiert.

Tätigkeitsbeschreibung II

10/2013 – 01/2014 Praktische Übung im Labor – Universität Stuttgart

■ Thema

Statistical Signal Processing – Automotive Radar

■ Aufgabe

1. Statistische Signalverarbeitung des Automobil - Radarsignals
2. Aufbau des gesamten Signalverarbeitungssystems
3. Bestimmung der Position und Geschwindigkeit des Objektes
4. Objekttracking
5. Implementierung in Matlab
6. Teamarbeit

■ Meine Tätigkeiten

1. Signalverarbeitung LFMCW - Radar
 - a) Einarbeitung in die Applikation des LFMCW – Radar für die Messung des Abstands und der Geschwindigkeit des Objektes
 - b) Empfangenes Signal ins Basisband heruntermischen
 - c) Zeitliches Signal mit FFT in die Frequenzdomäne umwandeln und Rauschen mit Hamming - Fenster unterdrücken
2. Peak Detektion mit Varianten des Constant False Alarm Rate Algorithmus
 - a) Implementierung Cell Averaging (CA) und Order Statistic (OS) – CFAR
 - b) Vergleich der Detektionsrate und Berechnungskomplexität
 - c) Validierung der OS - CFAR Algorithmus für Multi-Peak Detektion
 - d) Implementierung der Centre of Gravity Methode für Peak Interpolation
3. Abstimmung der Frequenz und Abschätzung des Abstandes und der Geschwindigkeit
 - a) Implementierung des Cross-Section Algorithmus für Abstimmung der Frequenz
Zwei von vier Rampen werden für die Berechnung der Frequenz verwendet, die anderen zwei dienen zu der Validierung der errechneten Frequenz
 - b) Auslöschung des Ghost-Objektes durch Zusammenlagerung
 - c) Abschätzung der Range und Velocity (Abstand und Geschwindigkeit)
 - d) Visualisierung des Berechnungsvorganges mit R-V Diagramm
4. Objekt Tracking
 - a) Implementierung des Kalman Filters für Objekt Tracking
 - b) Visualisierung des Trackings
5. Verteilte Versionsverwaltung für Matlab Code (Git) und Dateien
6. Aufgabe und Tätigkeit aufteilen.

Hinweis: Da die Masterarbeit komplett auf Englisch geschrieben wurde und ebenso die überwiegende Literatur im Themenfeld „Deep Learning und Machine Learning“ auf Englisch sind, sind im Folgenden die Inhalte der Tätigkeitbeschreibung III auf Englisch.

Tätigkeitsbeschreibung III

08/2013 – 02/2015 Masterarbeit – Universität Stuttgart

■ **Thema**

Deep Neural Network for learning speech emotion representations

■ **Aufgabe**

1. Pre-processing of speech signal
2. Implementation of models for unsupervised speech feature learning
3. Implementation of models for emotion classification
4. Optimization of model parameters and hyper-parameters
5. Programming in Python

■ **Meine Tätigkeiten**



speech emotion recognition system structure

1. Understood the source-filter model of speech signal production
2. Preprocessed speech emotion signal to extracted low-level features.
 - a) Extracted MFCC (Mel Frequency Cepstral Coefficients) features with FFT and Mel - filter bank, applied Discrete Cosine Transform (DCT) for decorrelation of coefficients
 - b) Normalized the amplitude in MFCC spectrum on the energy within the whole frame
3. Built, trained two models for feature learning. Speech emotion features are time-variant which require the model to capture variations of hidden patterns in both short and long period of time (1-1.5 s).
 - a) Unsupervised feature learning with Conditional Restricted Boltzmann Machine (CRBM), trained with Contrastive Divergence algorithm.
 - b) Supervised feature learning with Convolutional Neural Network (CNN), trained with back propagation algorithm.
4. Built, trained three models for supervised classification.

- a) Deep Neural Network (rectifier linear activation), trained with back propagation
 - b) Deep Neural Network (sigmoid activation), layer-wise pre-trained as auto-encoder and trained with back propagation
 - c) Long Short Term Memory (LSTM), trained with back propagation through time
5. Evaluated implemented models.
- Since the spectrum features are abstract and not evaluable with visualization, the evaluation of both models was done according to the error rate by performing classification.
6. Optimization CRBM-DNN (sigmoid/rectifier), CRBM-LSTM model parameters, weights, bias and length of temporal dependency.
7. Optimization the hyper-parameter with grid search technique.
- Hyper-parameters are training algorithm or model structure related parameters: learning rate, number of hidden units and hidden layers, number of training iterations, mini-batch size for stochastic gradient descent etc.